

Модель мира (RSSM) + оценка целей через VLM (CLIP) в MiniGrid

Мини-отчёт по демо-проекту: обучение компактной world model в стиле Dreamer/PlaNet, оценка текстовой цели предобученной VLM по «воображаемым» будущим кадрам и планирование (MPC / random shooting) в обученной модели мира. Сравнение с baseline: random и planning без VLM.

1. Задача и идея

Хотелось проверить одну гипотезу: можно ли задать агенту цель словами и довести его до неё, если оценивать зрительно-языковой моделью не то, что он видит сейчас, а то, что он увидит через несколько шагов. То есть агент воображает будущее внутри своей модели мира, а CLIP смотрит на это воображаемое будущее и говорит, насколько оно похоже на цель.

Конвейер устроен так:


- наблюдение (полный RGB-кадр сетки) кодируется в скрытое состояние модели мира;
- из этого состояния по заданной последовательности действий раскручивается развёртка на горизонт H — без обращения к среде, чисто «в голове» модели;
- предсказанные кадры декодируются, и CLIP превращает каждый в число от 0 до 1;
- планировщик перебирает несколько последовательностей, берёт лучшую по этому числу, делает её первый шаг и всё повторяется.

Сравниваются три способа выбирать действия: случайные действия (базовый уровень), награда, предсказанная самой моделью мира (планирование без VLM), и оценка CLIP по будущим кадрам.

2. Среда и данные

Среда — MiniGrid: основная MiniGrid-Empty-8x8-v0, для быстрых прогонов Empty-6x6-v0. Важный момент: наблюдением берётся не частичный символьный вид, а полный цветной рендер всей сетки — потому что CLIP училась на картинках, и хочется, чтобы модель мира и оценщик смотрели ровно на то же изображение. Действий оставлено три: повернуть налево, направо, шагнуть вперёд. Подсветка поля зрения агента выключена, чтобы кадр был однородным.

Данные для обучения модели мира собраны случайной политикой (400 эпизодов на среду) — для пустой комнаты этого достаточно, чтобы модель увидела разные положения агента. Агент — красный треугольник, цель — зелёная клетка.





Пример успешного эпизода (планирование по награде, 6x6): агент-треугольник дошёл до зелёной клетки-цели.
Наблюдение — полный RGB-рендер сетки.


3. World model в стиле Dreamer (RSSM)

Сердце работы — рекуррентная латентная модель (RSSM в духе PlaNet/Dreamer). Скрытое состояние разбито на две части: детерминированную h_t (память на GRU) и стохастическую z_t (гауссова). Есть два распределения на z_t : априор $p(z_t | h_t)$ предсказывает состояние без наблюдения — именно он крутит воображаемые развёртки; апостериор $q(z_t | h_t, e_t)$ уточняет z_t , увидев кадр. Модель учится на трёх слагаемых: восстановление кадра (reconstruction), согласование двух распределений (KL с free-nats) и предсказание награды.


Конфигурация обучения: `deter_dim=256`, `stoch_dim=32`, `embed_dim=1024`; 4000 шагов обучения на 6x6 и 8000 на 8x8. Модель умеет делать imagined rollouts на горизонте H (10 для 6x6, 12 для 8x8) без обращения к среде и декодировать по ним будущие кадры и reward.



Проверочная развёртка «воображаемое против реального»: слева — то, что реально происходит в среде, справа — что модель мира воображает по тем же действиям. Реконструкции достаточно аккуратные для коротких горизонтов.



Докуда можно верить воображению: расхождение воображаемого и реального кадра растёт с горизонтом развёртки. Это и ограничивает разумный H для MPC.



Что выучила модель мира: латентные состояния, спроецированные в 2D, упорядоченно раскладываются по расстоянию до цели — геометрия задачи в латентах действительно есть. Это косвенно объясняет надёжность планирования по награде.

4. VLM-based scorer (CLIP)

Оценщик построен на CLIP (openai/clip-vit-base-patch32). Цель задаётся парой наборов промптов — что «хорошо» и что «плохо». Позитив: «a red triangle on top of a green square»,

негатив: «a red triangle and a green square far apart». Близость нормированного визуального эмбединга кадра к этим текстам прогоняется через softmax из двух средних косинусных близостей — получается число от 0 до 1, что-то вроде «вероятности, что цель достигнута».

Ключевой момент под задачу: скорится не текущее наблюдение, а предсказанные будущие кадры развёртки. По горизонту оценки сворачиваются в одно число (в основных прогонах — оценка только финального кадра; в коде есть и дисконтированная сумма, и «последний + максимум»). Промпты подбирались руками, и оказалось, что пространственные формулировки («красный треугольник на зелёном квадрате») работают заметно лучше смысловых («агент достиг цели»). Версия ViT-B/16 пробовалась — не лучше B/32.

5. Планирование по imagined rollouts (MPC)

Отдельная политика не обучается. Вместо этого на каждом шаге решается маленькая задача оптимизации со скользящим горизонтом: перебираются несколько последовательностей действий длины H , каждая прогоняется через модель мира, оценивается функцией g (предсказанная награда — для метода без VLM, либо оценка CLIP — для метода с VLM), выбирается лучшая, выполняется её первый шаг, и всё повторяется.


Базовый поиск — случайный перебор (random shooting): 48 кандидатных последовательностей на шаг. Как необязательное улучшение реализован метод перекрёстной энтропии (CEM), итеративно подтягивающий распределение действий к лучшим кандидатам. Все три сравниваемых метода различаются только функцией g — планировщик у них общий.

6. Результаты (количественное сравнение)


Каждый метод прогнан на 20 эпизодах с общими seed'ами (seeds 0–19) — сравнение парное, разброс из-за стартовых позиций не мешает. Считаются доля успешных эпизодов (success rate), средний суммарный return и средняя длина эпизода.

Среда	Метод	Success rate	Return (сред.)	Длина (сред.)
6x6	random (baseline)	35%	0.191	52.9
	WM planning (reward)	80%	0.486	35.1
	WM planning + CLIP	40%	0.124	58.0
8x8	random (baseline)	25%	0.108	116.2
	WM planning (reward)	75%	0.395	82.5
	WM planning + CLIP	35%	0.094	119.7

Главный результат: планирование в модели мира работает — по предсказанной награде агент доходит до цели в ~75–80% эпизодов, сильно обгоняя случайного. А вот zero-shot CLIP оказался примерно на уровне random (40% на 6x6, 35% на 8x8) и заметно хуже планирования по награде. То есть схема world model + VLM работает технически, но конкретный CLIP-скор не даёт хорошего управляющего сигнала. Именно этот провал и запустил остальную часть работы.




MiniGrid-Empty-6x6-v0: success rate и средний return трёх методов (усы — стандартное отклонение по эпизодам).




MiniGrid-Empty-8x8-v0: та же картина сохраняется на большей среде.

7. Почему CLIP не сработал: диагностика

Первым делом нужно было понять, кто виноват: мутные воображаемые кадры (декодер модели мира) или сам CLIP. Разведение простое — отдельно проверяется качество реконструкции и отдельно корреляция оценки CLIP с настоящим расстоянием до цели, причём и на живых, и на восстановленных кадрах. Реконструкции оказались аккуратными (MSE маленький), а CLIP плохо коррелировал с достижением цели уже на живых кадрах. Значит, проблема не в декодере, а в самом zero-shot CLIP на MiniGrid-изображениях.




Карта CLIP-скор по клетке агента: если оценкой можно планировать, максимум должен сидеть на цели (звезда). На деле карта почти плоская, а её максимум (крестик) — не на цели. Планировать по такому сигналу фактически нечем.



Сигнал сильно зависит от формулировки промпта — иногда даже меняется знак корреляции с расстоянием до цели. Prompt engineering помогает мало.

Сравнение ViT-B/32 и ViT-B/16 не помогло: корреляция у обеих версий болтается около нуля. Значит, дело не в размере модели, а в domain gap — аккуратные «векторные» рендеры MiniGrid слишком далеки от фотографий, на которых росла CLIP.

Но информация в признаках CLIP всё же есть. Если заморозить CLIP и обучить поверх её эмбеддингов один логистический слой (linear probe), предсказывающий «агент близко к цели», а затем подставить его в тот же неизменный планировщик — корреляция с близостью подскакивает с почти нуля до рабочей, и в планировании probe уверенно обгоняет и zero-shot CLIP, и случайного агента (хотя до планирования по награде всё равно не дотягивает). Это, пожалуй, главный позитивный итог: провал zero-shot CLIP — не приговор.



Linear probe поверх frozen CLIP-признаков «вытаскивает» сигнал: в планировании он заметно лучше zero-shot CLIP и random, приближаясь к планированию по награде.


8. Основные failure modes

- Слабый zero-shot CLIP-сигнал на синтетических MiniGrid-рендерах: CLIP обучался на естественных изображениях и плохо «понимает» маленькие grid-world картинки (domain gap).
- Нет правильного пространственного градиента: скор не растёт стабильно при приближении к цели, а его максимум не на goal — MPC оптимизирует шумный/неверный сигнал.
- Сильная зависимость от промпта: формулировка заметно меняет скор, но не делает его стабильным.
- Mismatch между реальными и воображаемыми кадрами: probe учится на живых кадрах, а в планировании скорит decoded frames из модели мира — это разные распределения.
- Ошибка модели мира растёт с горизонтом: слишком длинные развёртки становятся ненадёжными и ограничивают H.

9. Что попробовать дальше (future work)


- Калибровать scorer на decoded imagined frames, а не только на реальных кадрах — это уменьшит domain gap между обучением скорера и его использованием в MPC.
- Обучать supervised reward model или linear probe поверх CLIP / SigLIP / DINO признаков: даже простой probe заметно улучшает сигнал.
- Смешать predicted reward и VLM-скор в одном objective — сохранить стабильность reward-планирования и добавить текстовую гибкость.
- Улучшать сам поиск (CEM) или дистиллировать MPC в actor-policy, чтобы агент действовал быстрее.
- Многошаговые задачи (DoorKey) — через цепочку subgoals, но им нужен directed data collection: под случайной политикой дверь почти не открывается, и CLIP слабо различает фазы эпизода.

случайный перебор и метод перекрёстной энтропии (E)



Бонус: CEM против random shooting на reward-objective. CEM даёт выше success rate, но стоит дороже по числу обращений к цели на шаг (важно, если цель — дорогой VLM).

DoorKey: subgoal-скор CLIP по фактической фазе



Проба переноса на DoorKey: CLIP слабо разделяет фазы «есть ключ» / «дверь открыта», а под случайной политикой дверь не открывается — нужен направленный сбор данных.